



Сегодня мы рассмотрим Hermes AI — это не просто чат-бот с искусственным интеллектом, а полноценный AI-агент, который ориентирован на выполнение задач и автоматизацию рабочих процессов. Hermes Agent разработан как открытый проект на базе технологий искусственного интеллекта и предназначен для того, чтобы работать как персональный цифровой помощник. В отличие от обычных чат-ботов, которые отвечают только на запросы пользователя в момент общения, Hermes может сохранять контекст, использовать инструменты, выполнять действия и постепенно адаптироваться под рабочие сценарии пользователя.

Основная идея Hermes заключается в переходе от модели «задал вопрос — получил ответ» к модели «поставил задачу — получил результат». Такой агент может подключаться к различным языковым моделям, работать с файлами, выполнять команды, использовать дополнительные инструменты и взаимодействовать с внешними сервисами. Например, его можно применять для помощи в программировании, анализа информации, автоматизации повторяющихся действий или управления личными рабочими процессами. Hermes поддерживает работу с разными провайдерами моделей, включая облачные решения и локальные модели, что дает пользователю больше контроля над тем, где и как обрабатываются данные.

Главное отличие Hermes от обычного AI-помощника заключается в концепции постоянного агента. Он может хранить накопленный опыт работы, создавать собственные навыки для повторяющихся задач и использовать их в будущем. Такой подход приближает искусственный интеллект к роли цифрового сотрудника, который не просто генерирует текст, а помогает выполнять реальные процессы. Hermes можно устанавливать локально или использовать через другие среды запуска, поэтому он интересен прежде всего разработчикам, исследователям и пользователям, которым важно больше контроля, автоматизации и возможности расширять возможности AI под свои задачи.

Слайд 1. Проекты и закреплённые сессии

Проект в Hermes — это рабочий контекст, связанный с конкретным каталогом и задачей. В левой панели перечислены уже обнаруженные проекты: среди них есть учебные, тестовые и реальные репозитории. Выбирая проект, мы даём агенту понятную отправную точку для поиска файлов, запуска команд и анализа кода. Это надёжнее, чем каждый раз вручную объяснять, где находится нужная папка.

Над списком проектов расположена область закреплённых сессий. Полезный диалог можно закрепить сочетанием Shift и щелчка, чтобы он не потерялся среди остальных чатов. Закреплённая сессия и проект решают разные задачи: проект задаёт рабочую область, а сессия сохраняет конкретный ход обсуждения и уже накопленный контекст.

При работе со студентами я советую сначала выбрать правильный проект, а затем создавать новую сессию. Так снижается риск, что агент начнёт читать или изменять файлы не в том каталоге. Если работа длительная, ключевые сессии лучше закреплять и давать им понятные названия.

Слайд 2. Выбор модели в новой сессии

Модель выбирается прямо в строке ввода, поэтому её можно подобрать до отправки первого запроса. В раскрытом списке видны модели, доступные через подписку ChatGPT или Codex. Рядом с названием отображаются параметры режима, например уровень рассуждения. Выбранная модель отмечена галочкой.

Модели различаются скоростью, качеством анализа, размером контекста и стоимостью использования. Для коротких справочных запросов разумно брать более быструю модель. Для сложной работы с кодом, архитектурой или большим количеством файлов лучше выбрать более сильную модель и при необходимости увеличить глубину рассуждения.

Команда «Обновить модели» заново получает доступный список у провайдера. Пункт «Изменить модели» ведёт к настройкам источников и состава списка. Это полезно, когда подключили новый аккаунт или эндпоинт, но модель ещё не появилась в выборе.

Слайд 3. Модели из пользовательских эндпоинтов

В общем списке могут находиться не только модели подписки, но и модели из собственных источников. Отдельными группами показаны Custom Endpoint и настроенный адрес `foundation-models.api.cloud.ru`. Внутри такого источника Hermes выводит обнаруженные модели: GigaChat, GLM, Kimi и другие.

Важно разделять два понятия. Провайдер или эндпоинт определяет, куда Hermes отправляет запрос. Идентификатор модели определяет, какую именно модель должен вызвать этот сервис. Поэтому одинаковое или похожее название модели ещё не означает одинаковые условия работы: могут отличаться инфраструктура, лимиты, цена и правила обработки данных.

Пользовательский эндпоинт удобен для корпоративного API, локального шлюза или совместимого сервиса. Перед учебной или рабочей сессией я проверяю, что выбран правильный источник, потому что именно он определяет, где фактически будет обрабатываться запрос.

Слайд 4. Режим рассуждения и уровень усилий

Параметр «Размышление» включает режим, в котором модель тратит больше вычислений на анализ задачи. Ниже выбирается уровень усилий: от минимального до ультра. Чем выше значение, тем больше времени модель может уделить проверке вариантов и промежуточных решений.

Максимальная глубина нужна не всегда. Простое переименование, поиск строки или краткое объяснение обычно не выигрывают от режима «Ультра». Сложное проектирование, диагностика неоднозначной ошибки или анализ большого репозитория, наоборот, могут потребовать высокого уровня. Правильная настройка помогает не расходовать время и лимиты там, где достаточно быстрого ответа.

Переключатель быстрого режима управляет приоритетом скорости обслуживания, если выбранный провайдер это поддерживает. Я подбираю сочетание модели, глубины рассуждения и быстрого режима под конкретную задачу, а не оставляю максимальные параметры по привычке.

Слайд 5. Голосовая диктовка

Кнопка микрофона запускает голосовую диктовку. Hermes преобразует речь в текст и помещает результат в поле запроса. Это удобно, когда задачу проще проговорить, чем печатать, особенно при длинном описании проблемы или во время демонстрации.

Диктовка не отправляет запрос автоматически: полученный текст нужно прочитать и при необходимости исправить. Распознавание может исказить имена файлов, команды, номера версий и англоязычные термины. Перед отправкой я всегда проверяю технические слова и явно называю расширения файлов или символы, если от них зависит смысл.

Всплывающие элементы рядом с микрофоном позволяют управлять голосовым вводом и звуком. Голос — это только способ ввода. Качество результата по-прежнему зависит от того, насколько точно сформулирована цель, какие ограничения указаны и к каким инструментам имеет доступ агент.

Слайд 6. Движок голосового чата

Для голосового общения можно выбрать один из двух подходов. Режим Speech-to-text вместе с Hermes Voice сначала преобразует речь в текст, передаёт её обычному агенту, а затем озвучивает ответ. Такой вариант сохраняет привычную логику текстовой сессии и хорошо подходит для задач, где агент должен пользоваться инструментами.

GPT-Live работает как полнодуплексный голосовой режим: разговор идёт более естественно, допускает быстрые реплики и перебивания, а выполнение содержательной работы делегируется Hermes. Это полезно для живого диалога, но важно понимать разделение ролей: голосовой движок отвечает за разговор, а основной агент — за работу с файлами и инструментами.

Выбор зависит от сценария. Для точной фиксации задания и последующей проверки текста я предпочитаю первый вариант. Для свободного обсуждения или устной консультации удобнее live-режим.

Слайд 7. Подтверждение действий агента

Режим подтверждения определяет, когда Hermes должен остановиться и спросить разрешение перед действием. В ручном режиме запрос появляется перед каждой операцией, которую система считает требующей подтверждения. Это самый контролируемый вариант, но при длинной цепочке действий он замедляет работу.

Умный режим оценивает риск автоматически и спрашивает только при необходимости. Обычно это хороший баланс для повседневной работы: безопасные шаги выполняются без лишних пауз, а потенциально опасные операции остаются под контролем пользователя.

Режим «Выкл» разрешает выполнять действия без запросов. Он выбран в показанной конфигурации, но подходит только для доверенной среды и понятной задачи. Если агент имеет доступ к терминалу, файлам, браузеру или внешним сервисам, отключение подтверждений увеличивает последствия ошибочно сформулированной команды. Для учебной практики лучше сначала использовать ручной или умный режим.

Слайд 8. Проверка версии Hermes Desktop

Окно обновления сообщает, что установлена последняя версия. В правом нижнем углу видны номер Hermes Desktop, идентификатор коммита и ветка сборки. Эти данные важны при воспроизведении ошибки: один и тот же интерфейс или настройка могут вести себя по-разному в разных версиях.

Перед занятием я проверяю обновления заранее, а не во время практики. После обновления могут измениться названия пунктов, доступные модели или расположение параметров. Если студент сообщает о проблеме, первым делом нужно сравнить версию приложения и сборки, а затем уже искать причину в настройках.

Сообщение «Всё готово» подтверждает только актуальность установленной версии. Оно не проверяет подключение модели, доступность провайдера или разрешения инструментов. Эти компоненты диагностируются отдельно.

Слайд 9. Вложения и фрагменты промптов

Кнопка с плюсом открывает все способы добавить контекст к запросу. Можно прикрепить отдельные файлы, целую папку, изображения, вставить изображение из буфера обмена или передать URL. Отдельный пункт открывает сохранённые фрагменты промптов, чтобы повторно использовать заготовленные инструкции.

Папка полезна, когда агенту нужно увидеть структуру небольшого проекта. Для большой кодовой базы лучше выбрать проект и указать конкретную область, иначе в контекст попадёт слишком много лишнего. Изображения подходят для интерфейсов, схем и сообщений об ошибках, а URL — для страницы, которую нужно открыть или проанализировать.

Подсказка с символом @ показывает ещё один способ ссылаться на файлы прямо в тексте. Такая ссылка делает задание точнее: вместо общего «проверь код» мы указываем конкретный файл и формулируем ожидаемый результат.

Слайд 10. Навыки и каталог Skills Hub

Раздел «Возможности» объединяет навыки, инструменты, MCP-серверы и плагины. Во вкладке навыков перечислены установленные пакеты инструкций. Каждый навык можно включить или выключить, а справа отображаются его назначение и служебные сведения: имя, версия, автор, лицензия и поддерживаемые платформы.

Выбранный навык `codebase-inspection` предназначен для инспекции кодовой базы и сбора метрик, например количества строк и распределения языков. Навык не обязательно добавляет новый исполняемый инструмент. Часто он описывает агенту проверенный порядок действий и правила использования уже доступных средств.

Нижняя часть содержит Skills Hub — каталог, из которого можно найти и установить дополнительные навыки. Подключать всё подряд не нужно. Чем меньше лишних инструкций получает агент, тем легче предсказать его поведение. Изменения в составе навыков применяются к новым сессиям, поэтому после настройки лучше открыть новый чат.

Слайд 11. Встроенные инструменты и протокол A2A

Во вкладке «Инструменты» перечислены группы исполняемых возможностей. Browser Automation управляет браузером, Code Execution запускает код, File Operations читает и изменяет файлы, Cron Jobs работает с расписанием, а Memory и Session Search обращаются к сохранённому контексту. Число рядом с группой показывает количество инструментов внутри неё.

Переключатель отключает всю группу. Это простой способ применить принцип минимальных полномочий: если задаче не нужен браузер или генерация изображений, соответствующий доступ можно убрать. Изменения применяются к новым сессиям.

Выбранная группа A2A реализует Agent-to-Agent Protocol. Она позволяет обнаруживать других совместимых агентов, отправлять им задания, получать историю и координировать несколько исполнителей. Такой обмен расширяет архитектуру за пределы одного агента, но одновременно требует контроля адресов, токенов и входящих запросов. Поэтому A2A в показанной конфигурации выключен.

Слайд 12. MCP-серверы

MCP-сервер предоставляет агенту внешние инструменты через стандартный протокол Model Context Protocol. Hermes поддерживает локальные серверы, запускаемые через `studio`, и удалённые HTTP-серверы. Кнопка «Новый сервер» создаёт подключение, а команда импорта позволяет перенести готовую конфигурацию.

Справа доступен файл `mcp.json`. В нём серверы можно описать явно, а затем сохранить конфигурацию. Когда список пуст, объект `mcpServers` остаётся пустым. Такой файл удобно хранить и проверять, потому что в нём видно, какие процессы или адреса получают доступ к агенту.

Встроенный каталог предлагает готовые подключения к Airtable, Algolia, Asana, Atlassian и другим сервисам. Установка не отменяет авторизацию: многие серверы требуют OAuth или отдельные учётные данные. Подключать MCP нужно осознанно, так как каждый сервер расширяет доступ агента к данным и действиям.

Слайд 13. Плагины Hermes

Плагин может расширять настольное приложение, самого агента или обе части сразу. Поэтому у каждой строки есть отдельные переключатели Desktop и Agent in Hermes. Например, встроенный плагин Bots добавляет вкладку и интерфейс ботов в приложение, а агентная часть при этом может отсутствовать.

Плагины устанавливаются из каталога, из Git-репозитория или из локальной папки. Кнопка обновления перечисляет установленный набор. В каталоге доступны плагины для памяти, голоса, сообщений, браузера и дополнительных панелей.

Важно отличать плагины от навыков. Навык в основном направляет поведение агента в определённом типе задач. Плагин изменяет возможности приложения и может добавлять собственный код, интерфейс или инструменты. Поэтому перед установкой нужно проверить источник, назначение и требуемые права, а ненужные части плагина лучше оставить выключенными.

Слайд 14. Подключение мессенджеров

Hermes может принимать сообщения не только из собственного окна. В списке доступны Telegram, Discord, Slack, Mattermost, Matrix, WhatsApp, Signal, электронная почта и другие каналы. Каждый канал настраивается отдельно.

Для Telegram предлагается быстрый вариант через QR-код. Hermes создаёт бота и автоматически определяет Telegram ID пользователя. Ручная настройка требует получить токен у `@BotFather`, вставить его в поле и сохранить изменения.

Особое внимание нужно уделить списку разрешённых ID. Без ограничения написать боту может посторонний человек, а агент будет воспринимать его сообщение как входящее задание. Я рекомендую явно перечислять допустимые аккаунты, особенно если у агента есть доступ к файлам или внешним сервисам. После настройки канал сначала проверяют на безопасной тестовой команде.

Слайд 15. Библиотека артефактов

Артефакт — это самостоятельный результат работы агента, а не просто текст сообщения. Сюда попадают созданные изображения, файлы и ссылки. Фильтры «Все», «Изображения», «Файлы» и «Ссылки» помогают быстро найти нужный результат среди разных сессий.

Пока агент ничего не создал, библиотека пуста. После генерации документа, изображения, отчёта или другого файла объект появляется здесь автоматически. Это удобно для повторного открытия результата без поиска по длинной истории диалога.

Я разделяю промежуточные ответы и итоговые артефакты. Обсуждение можно оставить в чате, а материал, который нужно передать студентам или использовать дальше, лучше попросить сохранить отдельным файлом с понятным названием. Тогда результат легче проверить, скачать и версионировать.

Слайд 16. Запланированные задачи

Запланированная задача — это промпт, который Hermes выполняет по cron-расписанию и доставляет результат в выбранное место. Можно создать задачу с нуля или взять шаблон: утренний обзор, мониторинг важной почты, еженедельный отчёт, напоминание, новостную сводку или наблюдение за ценой.

Автоматизация состоит минимум из трёх частей: точного задания, расписания и места доставки результата. Если промпт сформулирован расплывчато, система будет регулярно воспроизводить одну и ту же неопределённость. Если задача обращается к почте, браузеру или внешнему сервису, соответствующий инструмент и авторизация должны оставаться доступными.

Расписание не делает агента полностью независимым от инфраструктуры. Шлюз Hermes должен работать, а компьютер или удалённая среда — быть доступны в момент запуска. Поэтому после создания я выполняю задачу вручную один раз и проверяю результат, прежде чем полагаться на регулярный запуск.

Слайд 17. Пустой (удалять не стал чтобы не поехала следующая нумерация)

Слайд 18. Создание профиля

Профиль — это независимая среда Hermes со своими настройками, навыками и файлом `SOUL.md`. Такая изоляция полезна, когда один и тот же экземпляр приложения используется для разных задач: например, один профиль для разработки, другой для обучения, третий для работы с внутренними данными.

Имя профиля записывается латинскими строчными буквами, цифрами, дефисами и подчёркиваниями. Оно должно начинаться с буквы или цифры. Можно клонировать существующий профиль, чтобы перенести его настройки и навыки, а затем изменить только нужные параметры.

Поле `SOUL.md` задаёт системный промпт и персону. Здесь фиксируют роль, стиль ответа, ограничения и постоянные правила. Если поле оставить пустым при клонировании, сохранится исходное содержимое. Перед созданием профиля я формулирую в `SOUL.md` только действительно постоянные требования, а конкретные задания оставляю для обычных запросов.

Слайд 19. Управление профилями и файл SOUL.md

Менеджер профилей показывает путь к среде, выбранную модель, количество навыков и содержимое `SOUL.md`. Профиль `default` отмечен как профиль по умолчанию. Значок `.Env` указывает, что среда может использовать собственные переменные окружения.

Текст в `SOUL.md` действует как постоянная системная инструкция для всех новых сессий этого профиля. В показанном примере агенту предписано отвечать прямо, соотносить длину ответа со сложностью задачи, не пересказывать запрос и не скрывать сомнения. Такие правила заметно влияют на поведение, поэтому их нужно писать конкретно и без противоречий.

После изменения файл требуется сохранить отдельной кнопкой. Я не помещаю сюда временные сведения о текущем проекте: для них лучше использовать запрос, проектные инструкции или навык. `SOUL.md` должен описывать устойчивую роль и общие принципы работы профиля.

Слайд 20. Управление сессиями

Системное окно объединяет четыре административных раздела: сессии, состояние системы, статистику использования и обслуживание. Во вкладке «Сеансы» можно искать и управлять сохранёнными сессиями, представлениями и связанными действиями.

Это отличается от обычного списка чатов слева. Там мы выбираем текущий разговор, а здесь получаем общий административный обзор. Если сессий нет, центральная область остаётся пустой.

При большом количестве диалогов поиск помогает найти историю по названию или содержанию. Сессии стоит именовать по задаче, а не оставлять случайные заголовки. Тогда легче понять, какой контекст можно продолжить, а какой разговор уже неактуален.

Слайд 21. Состояние системы и журналы

Раздел «Система» показывает, работает ли шлюз сообщений, какую версию Hermes мы используем и сколько сессий активно. Отсюда можно перезапустить шлюз или запустить обновление приложения. Перезапуск нужен, когда интерфейс открыт, но сообщения, инструменты или внешние каналы перестали отвечать.

Ниже расположен журнал. Записи можно фильтровать по компоненту: agent, errors, gateway или desktop, а также по уровню info, warning и error. Строковый фильтр помогает найти название провайдера, инструмента или конкретный код ошибки.

В примере повторяются предупреждения о деградации обмена токена Copilot до RAW token и возможной недоступности части моделей. Такой журнал даёт фактическую причину поведения системы. При диагностике я сначала фиксирую время сбоя, затем ищу записи за этот интервал и только после этого меняю настройки. Одинокое предупреждение ещё не означает отказ, но повторяющиеся записи показывают устойчивую проблему.

Слайд 22. Статистика использования

Статистика собирает данные о работе Hermes за 7, 30 или 90 дней. Верхние показатели отражают количество сессий, вызовов API и токенов на входе и выходе. График показывает ежедневную активность, а нижние блоки — наиболее используемые модели и навыки.

Входные токены включают запрос, историю и добавленный контекст. Выходные токены относятся к ответу модели. Рост входного объёма часто связан с длинной сессией, большим количеством файлов или недостаточным сжатием контекста. Рост числа API-вызовов может означать активное использование инструментов или повторные попытки.

Эта статистика нужна не только для контроля расходов. Она помогает сравнить профили, заметить слишком тяжёлые сценарии и понять, действительно ли используются подключённые навыки. Пустые значения означают отсутствие активности за выбранный период, а не неисправность счётчика.

Слайд 23. Обслуживание Hermes

Раздел обслуживания объединяет диагностику, резервные копии и управление памятью. Команда doctor проверяет состояние установки, конфигурации и провайдеров. Аудит безопасности ищет рискованные настройки в конфигурации и навыках.

Резервная копия упаковывает конфигурацию, память, навыки и сессии в ZIP-архив. Её стоит создавать перед крупным обновлением или экспериментом с профилем. Функция «Поделиться отладкой» формирует анонимизированный отчёт и журналы, загружает их и выдаёт временную ссылку, которая удаляется через шесть часов.

Куратор навыков работает в фоне и архивирует устаревшие навыки, созданные агентом. Его можно приостановить или запустить вручную. Внизу находятся отдельные команды сброса `MEMORY.md` и `USER.md`. Это уже удаление накопленного контекста, поэтому перед сбросом нужно убедиться, что важные сведения сохранены в другом месте.

Слайд 24. Быстрая панель шлюза

Индикатор в нижней части окна открывает краткую панель состояния шлюза. Здесь видно, что соединение установлено и механизм инференса готов. Это быстрая проверка перед отправкой задания: приложение может быть открыто, но без готового шлюза запрос не дойдёт до модели и инструментов.

Панель показывает недавнюю активность и даёт переход ко всем журналам. Служебные сообщения о запуске планировщика, веб-сервера и компонентов интерфейса помогают понять, какие подсистемы действительно поднялись. Рядом расположены команды управления соединением, включая перезапуск и остановку.

Если запрос завис, я сначала проверяю два статуса: подключение шлюза и готовность инференса. Затем открываю журналы за последние минуты. Такой порядок быстрее, чем сразу менять модель или переустанавливать приложение.

Слайд 25. Создание бота

Бот в Hermes — это отдельный именованный участник со своей памятью, навыками и чатом. Он может обмениваться сообщениями с другими агентами. Вкладка Bots отделяет таких постоянных помощников от обычных пользовательских сессий.

При создании выбирается внешний образ. Можно взять готовую форму, сгенерировать изображение, загрузить собственное или выбрать вариант питомца. Кнопка Randomize меняет лицо, а Lock face закрепляет его, чтобы последующие изменения не затронули выбранный образ.

Поле Name задаёт техническое имя, Title — отображаемое название, Description — назначение бота. Описание лучше формулировать через конкретную ответственность, например разбор входящей почты или проверку учебных работ. Чем уже роль, тем проще подобрать боту навыки, память и права доступа.

Слайд 26. Основная модель и источник подключения

Настройка основной модели применяется к новым сессиям. В активном чате модель меняется через селектор в строке ввода. Сначала выбирается источник: подписка ChatGPT или Codex, OpenAI API, пользовательский эндпоинт либо настроенный облачный сервис. После этого выбирается конкретная модель этого источника.

Ниже можно вручную переопределить обнаруженный размер контекстного окна основной модели. Значение задаётся в токенах. Ноль означает, что Hermes использует размер, сообщённый провайдером. Ручное значение оправдано только тогда, когда сервер сообщает неверный лимит. Завышенный размер приведёт к ошибкам при слишком длинном запросе, а заниженный — к преждевременному сжатию контекста.

Эта настройка не влияет на вспомогательные модели и модели Mixture of Agents. Для них существуют отдельные разделы.

Слайд 27. Резервные модели

Резервные модели образуют цепочку отказоустойчивости. Если основная модель не отвечает, Hermes по очереди пробует записи вида `provider:model`. Если список пуст, при отказе основной модели запасного варианта нет.

Резервная модель должна быть доступна через уже настроенный провайдер и подходить по возможностям. Например, если основная задача требует анализа изображений или большого контекста, текстовая модель с малым окном не станет полноценной заменой. Порядок списка тоже важен: первым ставят наиболее близкий по качеству и возможностям вариант.

Переключение помогает пережить временный сбой сервиса, но не устраняет различия между моделями. Ответ может отличаться по стилю, поддержке инструментов и точности. В критическом процессе нужно явно учитывать, что результат мог получить резервный исполнитель.

Слайд 28. Вспомогательные модели

Не все служебные операции обязана выполнять основная модель чата. Hermes позволяет назначить отдельную модель для анализа изображений, сжатия контекста, поиска навыков, автоматического одобрения, маршрутизации MCP, генерации заголовков, ревью и подготовки спецификации для Kanban.

По умолчанию каждая задача использует основную модель. Кнопка «Изменить» задаёт специализированную. Например, для генерации заголовка достаточно небольшой быстрой модели, а для качественного ревью кода можно выбрать более сильную. Такое распределение снижает стоимость и ускоряет работу, не ослабляя ключевой этап.

Команда «Сбросить всё на основную» возвращает единое поведение. Перед разделением ролей нужно проверить совместимость провайдера и модели с конкретной служебной задачей. Иначе оптимизация создаст дополнительные точки отказа.

Слайд 29. Совместная работа моделей

Mixture of Agents позволяет сохранить набор моделей как отдельный пресет. После включения пресет появляется в обычном выборе моделей. В нём есть модели-консультанты Reference и модель-агрегатор.

Консультанты дают рекомендации, обычно один раз за пользовательский ход. Они могут представлять разные семейства и провайдеров, чтобы предложить независимые варианты. Агрегатор является действующей моделью: он выполняет каждый шаг цикла инструментов, сопоставляет советы и формирует результат. Основная часть стоимости запуска относится именно к его провайдеру.

Несколько моделей полезны для сложной проверки или сравнения подходов, но увеличивают задержку и расход токенов. Я применяю такой режим только там, где независимые мнения действительно повышают качество, а для обычных операций оставляю одну модель.

Слайд 30. Поведение чата

В разделе поведения задаются постоянные параметры общения. Поле «Личность» выбирает готовый стиль или отключает его. Часовой пояс указывается идентификатором IANA, например `Asia/Yekaterinburg`. Если значение пустое, используется системный часовой пояс.

Часовой пояс особенно важен для расписаний, напоминаний и запросов со словами «сегодня», «завтра» или «к вечеру». Ошибка здесь может сместить запуск автоматической задачи на несколько часов.

Переключатель блоков рассуждений управляет отдельным отображением рассуждений в интерфейсе, если модель и провайдер поддерживают такой формат. Он не заменяет выбор глубины рассуждения у модели. Это настройка представления и обработки соответствующих блоков в чате.

Слайд 31. Изображения во вложениях

Параметр максимального размера определяет, какой локальный файл Hermes загрузит для предварительного просмотра и передачи как вложение. В примере установлен лимит 16 МБ. Для удалённых вложений действует отдельный жёсткий предел 256 МБ.

Слишком большое значение опасно тем, что приложение может загрузить весь файл в память, зависнуть или завершиться с ошибкой. Поэтому лимит увеличивают только под конкретную необходимость, а тяжёлые изображения заранее уменьшают или передают в подходящем формате.

Режим «Вложения изображений» со значением Auto позволяет Hermes автоматически выбрать способ передачи. Если модель не поддерживает изображения, наличие файла ещё не означает, что она сможет его проанализировать. Тогда нужно назначить модель зрения во вспомогательных настройках или выбрать мультимодальную основную модель.

Слайд 32. Проекты и поиск репозиториев

Рабочий каталог задаёт базовую папку, от которой Hermes строит файловый контекст. Значение  означает текущий каталог запуска. Для предсказуемой работы лучше использовать конкретную рабочую область, особенно если на компьютере много несвязанных проектов.

Автоматическое обнаружение репозиториев сканирует локальные папки и добавляет найденные Git-репозитории в список проектов. Корни обнаружения ограничивают места поиска, а исключаемые пути позволяют пропустить архивы, каталоги зависимостей или другие ненужные области.

Чем шире корень сканирования, тем дольше поиск и тем больше лишних проектов появится в интерфейсе. Я задаю несколько явных каталогов с исходным кодом и исключаю объёмные служебные папки. Это не ограничение безопасности само по себе, а настройка обнаружения и удобства навигации.

Слайд 33. Персистентная оболочка

Персистентная оболочка сохраняет один и тот же процесс командной строки между вызовами инструментов. Благодаря этому не теряются текущий каталог, активированное виртуальное окружение и другие изменения состояния оболочки. Без неё каждый запуск может начинаться в новой чистой сессии.

Такой режим удобен для разработки и последовательной диагностики, но состояние становится менее очевидным. Команда, выполненная раньше, может повлиять на следующий шаг. Поэтому агент должен явно сообщать о смене каталога, активации окружения и запущенных фоновых процессах.

Поле пропуска переменных окружения перечисляет значения, которые не следует передавать в оболочку. Сюда имеет смысл включать секреты и переменные, не нужные для выполнения команд. Это уменьшает риск случайного раскрытия данных дочернему процессу.

Слайд 34. Выполнение кода и чтение файлов

Режим выполнения кода определяет область, в которой Hermes запускает команды. Значение Project привязывает выполнение к выбранному проекту. Это помогает сохранять понятный рабочий каталог и уменьшает вероятность действий в посторонней папке.

Лимит чтения файла задаёт максимальное число символов, которое Hermes получает за один запрос к файлу. В примере это 100 000 символов. Ограничение защищает контекст от случайной загрузки огромного журнала, сгенерированного файла или минифицированного кода.

Если нужный файл больше лимита, его не обязательно читать целиком. Правильнее искать конкретный фрагмент, читать по частям или использовать инструмент анализа. Увеличение лимита оправдано только когда важна большая непрерывная область текста.

Слайд 35. Подтверждения и разрешённые команды

В настройках безопасности режим подтверждения задаётся глобально. Значение Off означает выполнение без запросов. Тайм-аут 300 секунд определяет, сколько Hermes ждёт ответа пользователя, когда подтверждение всё же требуется.

Отдельный переключатель требует подтверждать перезапуск MCP-сервера. Это полезно, потому что перезапуск может прервать активные инструменты или изменить доступность внешнего сервиса. Список разрешённых команд задаёт команды, которые можно выполнять без дополнительного вопроса.

Белый список нужно формировать узко. Разрешение слишком общей оболочки фактически открывает множество вложенных действий. Для учебной среды безопаснее включить умный или ручной режим, оставить подтверждение перезапуска MCP и добавлять только конкретные безопасные команды.

Слайд 36. Приватность и сеть

Функция скрытия секретов включена. Hermes старается маскировать ключи, токены и другие чувствительные значения в выводе и журналах. Это снижает риск случайно показать секрет на экране или передать его модели, но не заменяет правильное хранение учётных данных.

Разрешение частных URL выключено. Частными считаются адреса локального компьютера и внутренней сети. Блокировка защищает от случайного обращения агента к внутренним панелям, маршрутизатору, базе данных или служебному API.

Если для задания действительно нужен локальный сервис, доступ включают осознанно и проверяют конкретный адрес. Открывать всю внутреннюю сеть ради одного ресурса не следует. Секреты лучше хранить в менеджере паролей или специализированном хранилище, а не вставлять в запрос.

Слайд 37. Контрольные точки файлов

Файловые контрольные точки сохраняют состояния, к которым можно вернуться после изменений агента. В показанной конфигурации функция выключена. При включении Hermes сможет создавать ограниченное число снимков перед операциями с файлами.

Контрольная точка полезна, когда агент массово редактирует проект и изменения ещё не зафиксированы в системе контроля версий. Она даёт дополнительную страховку, но не заменяет Git, резервную копию и проверку диффа.

Снимки занимают место и требуют обслуживания, поэтому их количество ограничивается отдельно. Для одноразового чтения файлов они не нужны. Для практики с автоматическими правками я включаю контрольные точки либо заранее создаю чистый коммит, чтобы результат можно было безопасно сравнить и отменить.

Слайд 38. Использование реального профиля браузера

Опция Use My Real Browser Profile позволяет агенту работать с существующими входами, cookies и настройками браузера. Hermes копирует профиль браузера по умолчанию в управляемый снимок и запускает собственный Chromium с этой копией. Исходный живой профиль напрямую не открывается.

Копия обновляется при каждом запуске. Это позволяет открыть локальную сессию реального профиля, даже если основная облачная браузерная сессия уже настроена. Поддерживаются браузеры на базе Chromium: Chrome, Edge, Brave и Chromium.

Удобство сопровождается риском: агент получает доступ к уже авторизованным сайтам. По умолчанию функция выключена. Я включаю её только для доверенной задачи и сначала проверяю, какие аккаунты открыты в профиле. Для учебной демонстрации безопаснее отдельный браузерный профиль без личных данных.

Слайд 39. Локальные и частные URL в браузере

Здесь разделены два связанных разрешения. «Частные URL браузера» позволяет браузерному инструменту обращаться к адресам локального компьютера и внутренней сети. «Локальный браузер для частных URL» направляет такие адреса через браузер на текущей машине.

В показанной конфигурации общий доступ к частным URL выключен, а использование локального браузера для них подготовлено. Пока первое разрешение закрыто, агент не должен свободно открывать внутренние адреса.

Такой доступ нужен для локального веб-приложения, панели разработки или сервиса в корпоративной сети. Перед включением я ограничиваю задачу конкретным адресом и проверяю, нет ли рядом административных интерфейсов. Частная сеть не становится безопасной только потому, что она недоступна из интернета.

Слайд 40. Сохранённые учётные данные

Hermes может сохранять логины для сайтов и подставлять их прямо в страницу. При первом входе агент просит пользователя ввести данные. Они шифруются на этом компьютере, а модель не получает сам пароль.

Учётную запись можно добавить заранее кнопкой Add или сохранить во время первого входа. После этого достаточно попросить агента войти на сайт, и Hermes заполнит форму через защищённый механизм.

Список пока пуст, поэтому автоматический вход недоступен. Я не передаю пароль обычным сообщением в чат: текст запроса становится частью истории. Для учебной работы лучше использовать тестовые аккаунты с минимальными правами и отдельными данными, которые не связаны с личными сервисами.

Слайд 41. Подключение менеджеров паролей

Hermes умеет автоматически обнаруживать командные инструменты 1Password и Bitwarden. Для работы нужно установить соответствующую CLI-программу и заранее войти в неё. В показанной среде оба менеджера не обнаружены.

Когда агенту впервые за сессию требуется логин, Hermes просит пользователя разблокировать менеджер. В памяти остаётся только временный токен текущей сессии. Мастер-пароль и сами учётные данные агенту не передаются.

Такой подход безопаснее ручного копирования пароля в чат или переменную окружения. При этом права всё равно нужно контролировать: разблокированный менеджер может содержать много записей. Для автоматизации лучше создать отдельное хранилище или коллекцию с доступом только к нужным сервисам.

Слайд 42. Постоянная память и профиль пользователя

Постоянная память переносит полезные сведения между сессиями. Профиль пользователя хранит устойчивые предпочтения и информацию о самом пользователе. Эти механизмы включаются отдельно, поэтому можно сохранять рабочие факты, но не формировать персональный профиль, или наоборот.

Бюджет памяти и бюджет профиля ограничивают объём текста, который Hermes добавляет в контекст. В примере память получает 2200 единиц бюджета, профиль — 1375. Чем больше эти значения, тем больше постоянных сведений видит модель, но тем меньше места остаётся для текущей задачи.

Провайдер памяти выбран встроенный. Я сохраняю в памяти только факты, которые действительно пригодятся позже: договорённости проекта, устойчивые предпочтения и проверенные ограничения. Временные детали и секреты туда помещать не следует. Очистить память и профиль можно отдельно в разделе обслуживания.

Слайд 43. Контекст и автоматическое сжатие

Контекстное окно модели ограничено. Когда история растёт, Hermes использует движок Compressor, чтобы сократить старую часть разговора и сохранить основные факты. Автоматическое сжатие включено.

Порог 0,5 задаёт момент запуска относительно доступного контекста, а целевое сжатие 0,2 определяет желаемый размер результата. Для поддерживаемых моделей ChatGPT Codex отдельная опция поднимает порог до 85 процентов, чтобы дольше сохранять исходные сообщения. Последние 20 сообщений защищены от сжатия.

Тайм-аут 120 секунд ограничивает ожидание вспомогательной модели сжатия. Медленной локальной модели может понадобиться больше времени. Сжатие освобождает контекст, но является пересказом: мелкие детали могут потеряться. Поэтому важные требования лучше закреплять в проектных инструкциях, памяти или отдельном файле, а не оставлять только в начале длинного чата.

Слайд 44. Приложение и запуск

Дополнительные параметры управляют поведением настольного приложения. Запрет сна позволяет продолжать долгие или ночные задачи, даже если экран погаснет. Отключение F12 блокирует открытие инструментов разработчика по обычной клавише, но альтернативное сочетание остаётся доступным.

Warm Bot Backends задаёт число заранее запущенных бэкендов ботов. Большее значение ускоряет переключение между ботами, но каждый процесс расходует около 60 МБ памяти. Backend Idle Timeout определяет, сколько миллисекунд неиспользуемый бэкенд остаётся тёплым; в примере это 600 000 миллисекунд, то есть десять минут.

Быстрый ввод вызывает маленькое окно глобальным сочетанием клавиш и отправляет запрос без открытия основного интерфейса. При обновлении из приложения локальные изменения можно временно убрать через Stash. Это важно для разработческой сборки, но сохранённые локальные изменения всё равно нужно затем проверить и вернуть осознанно.

Слайд 45. Ограничения запуска агента

Максимум шагов агента ограничивает количество ходов с инструментами. Значение 500 даёт большой запас для сложной задачи, но одновременно позволяет ошибочному циклу работать долго. Для учебной практики разумно начинать с меньшего лимита и повышать его только для действительно длинного процесса.

Повторы API равны трём. Hermes повторит временно неудачный запрос, но после исчерпания попыток завершит шаг с ошибкой. Слишком большое число повторов скрывает устойчивую проблему и увеличивает задержку.

Уровень сервиса управляет скоростным режимом провайдера. Описание различает fast, auto и cold: постоянный приоритет, приоритет в начале каждого хода или только в первом ходе. Если провайдер не поддерживает такую функцию, значение оставляют пустым. Эти ограничения защищают систему от бесконечных циклов и неконтролируемого расхода ресурсов.

Слайд 46. Доступ к инструментам

Поле включённых наборов определяет, какие комплекты инструментов доступны агенту. В примере указан набор `hermes-cli`. Набор объединяет связанные команды и позволяет централизованно менять доступ вместо настройки каждого инструмента отдельно.

Принудительное использование инструментов со значением Auto оставляет решение модели: она может ответить текстом или вызвать инструмент, если задача этого требует. Более строгая политика может заставлять модель обязательно использовать инструмент, но для обычного общения это создаёт лишние вызовы.

Я подключаю только те наборы, которые соответствуют роли профиля. Агенту для объяснения теории не нужен полный доступ к терминалу, а агенту-разработчику он необходим. Ограничение на уровне набора дополняет подтверждения и права операционной системы, но не заменяет их.

Слайд 47. Сервер терминала и среды выполнения

Бэкенд выполнения определяет, где запускаются команды терминала. Значение Local выполняет их на текущем компьютере. Для изоляции или удалённой работы могут использоваться Docker, Singularity, Modal и Daytona.

Тайм-аут команды установлен на 180 секунд. По истечении этого времени Hermes прекращает ожидание. Длительную сборку или обучение модели нельзя бездумно помещать в короткий синхронный вызов: нужно либо увеличить лимит, либо организовать фоновый процесс с понятным журналом.

Для контейнерных и облачных бэкендов задаются образы среды, например образ с Python и Node.js. Образ определяет доступные интерпретаторы и библиотеки. Локальный режим быстрее настраивается, но получает доступ к реальной машине. Изолированная среда безопаснее для эксперимента, однако требует подготовки образа и явного переноса файлов.

Слайд 48. Настройки субагентов

Субагент получает отдельную ограниченную задачу от основного агента. Для него можно выбрать собственную модель и провайдера. Если поля не заполнены, Hermes использует значения по умолчанию.

Лимит ходов 250 ограничивает длительность работы одного субагента. Параллельно разрешено до десяти субагентов. Такое число ускоряет независимые проверки, но умножает нагрузку, расход токенов и количество результатов, которые основному агенту нужно объединить.

Тайм-аут субагента сейчас равен нулю, то есть отдельное ограничение ожидания в этой конфигурации не задано. Глубина рассуждения задаётся отдельно для делегированных исполнителей. Я использую субагентов только для независимых частей задачи и формулирую каждому узкую ответственность, иначе параллельная работа создаёт дублирование и противоречия.

Слайд 49. Ограничения вывода

Лимиты вывода защищают интерфейс и контекст от чрезмерно больших результатов. Терминал ограничен 50 000 единицами вывода, файл — 2000 страницами представления, отдельная строка — 2000 символами. Hermes обрезает или делит данные, которые превышают эти значения.

Особенно опасны минифицированные файлы и журналы с очень длинными строками. Даже небольшой по размеру файл может занять значительную часть контекста. Вместо увеличения лимита лучше фильтровать вывод, искать нужный шаблон или читать диапазон строк.

Лимит контрольных точек равен двадцати. После его достижения старые снимки могут удаляться или переставать создаваться в зависимости от механизма хранения. Эти значения подбирают под размер проектов и доступную память, а не увеличивают заранее.

Слайд 50. Системные уведомления

Системные уведомления появляются средствами операционной системы, а не внутри окна Hermes. Общий переключатель включает или заглушает все категории на конкретном устройстве.

Отдельно настраиваются ситуации, когда требуется одобрение, нужен дополнительный ввод, готов ответ фоновой сессии, произошла ошибка, завершилась фоновая команда, изменился доступ к кредитам или пришло уведомление от плагина. Это помогает не следить постоянно за открытым окном.

Уведомления о завершении ответа срабатывают только когда Hermes находится в фоне. Кнопка тестового уведомления проверяет разрешения операционной системы. Я оставляю включёнными события, которые требуют действия пользователя, а второстепенные категории отключаю, чтобы важный сигнал не потерялся среди постоянных сообщений.

Слайд 51. Аккаунты провайдеров

Hermes поддерживает подключение через подписку, локальную модель или отдельный API-ключ. Вход по подписке проходит в браузере, поэтому ключ не нужно копировать вручную. В примере уже подключена подписка ChatGPT или Codex.

Nous Portal предлагается как рекомендуемый единый аккаунт с доступом к большому набору моделей. Ниже перечислены другие провайдеры, включая MiniMax, Qwen Code, xAI Grok и Anthropic. Для некоторых вход открывается в браузере, для других требуется команда в терминале.

Пункт Run models locally не требует аккаунта и переносит вычисления на этот компьютер. Выбор способа подключения влияет на стоимость, доступные модели, приватность и требования к оборудованию. Удаление подключённого аккаунта выполняется отдельно и не удаляет другие источники.

Слайд 52. API-ключи провайдеров

Если вход по аккаунту не используется, ключ можно сохранить в разделе API-ключей. Список содержит отдельную запись для каждого провайдера. Выбран OpenAI API, а сохранённое значение показано в маскированном виде.

Поле Base URL Override меняет базовый адрес API. Оно нужно для совместимого прокси, корпоративного шлюза или собственного сервера. Если используется официальный API, поле оставляют пустым. Неверный адрес приведёт к ошибке соединения или отправит запрос не тому сервису.

Ключ нельзя вставлять в учебный скриншот, репозиторий или обычный промпт. Даже маскированный интерфейс лучше демонстрировать на тестовой учётной записи. После сохранения я проверяю подключение коротким запросом и слежу, чтобы ключ не появился в журнале.

Слайд 53. Пользовательские эндпоинты

Пользовательский эндпоинт описывает совместимый API, которого нет среди готовых провайдеров. В примере активен `foundation-models.api.cloud.ru` с адресом версии API и моделью GigaChat. Карточка показывает имя, идентификатор провайдера, URL и модель по умолчанию.

Режим API можно определить автоматически или указать явно: Chat Completions, Responses API либо Anthropic Messages. Правильный режим зависит от протокола сервера. Поле Context задаёт размер контекстного окна, а пустое поле API Key при редактировании сохраняет уже записанный ключ.

Опции Use for new chats и Discover models позволяют использовать источник в новых сессиях и автоматически получать список моделей. Перед сохранением я нажимаю Test. Пользовательский эндпоинт удобен, но требует точной проверки URL, протокола, идентификаторов моделей и правил хранения данных у владельца сервиса.

Слайд 54. Локальные модели

Hermes предлагает автоматическую установку локального движка и модели Qwen3.8 27B. Указанный объём загрузки составляет 16,2 ГБ. После настройки модель можно назначить по умолчанию для новых чатов, а запросы не будут покидать этот компьютер.

Кнопка Set up for me автоматизирует установку, а Let me choose позволяет самостоятельно подобрать модель. Локальный запуск повышает контроль над данными и устраняет оплату каждого API-вызова, но требует достаточной оперативной или видеопамати и времени на загрузку.

Перед установкой я проверяю оборудование и свободное место. Для учебной машины большая модель может оказаться медленной. В таком случае лучше выбрать меньшую модель или облачный провайдер. Сам факт локального запуска не гарантирует качество, сопоставимое с крупной облачной моделью.

Слайд 55. Режимы подключения шлюза

Hermes отделяет настольный интерфейс от шлюза, который хранит и выполняет рабочие процессы. Можно запустить локальный шлюз на `localhost`, войти в Hermes Cloud, подключиться к удалённому бэкенду по адресу или запустить Hermes на удалённой машине через SSH.

Локальный режим работает офлайн и выбран по умолчанию. Cloud упрощает подключение к управляемой среде. Удалённый шлюз подходит для уже развернутого сервера, а SSH автоматически туннелирует соединение при наличии рабочей аутентификации по ключу.

Параметр шифрования сохранённых секретов использует системное хранилище ключей: Windows DPAPI, Keychain или GNOME Keyring. Когда он выключен, файлы доступны учётной записи пользователя в обычном виде. Для рабочей среды шифрование предпочтительно. При проблемах с запуском шлюза можно открыть `desktop.log` через диагностическую ссылку.

Слайд 56. Сохранённые подключения к шлюзам

Список подключений объединяет текущее устройство и все шлюзы, доступные через удалённый адрес, SSH или облако. Текущий локальный шлюз помечен как основной и управляемый приложением. Его состояние можно проверить отдельной кнопкой.

Профили, чаты, мессенджеры и cron-задачи остаются на том шлюзе, где были созданы. Переключение интерфейса на другой шлюз не переносит эти данные и не останавливает работу прежней среды. Это важное свойство: шлюз является самостоятельным местом выполнения и хранения контекста.

Опция возврата к последнему шлюзу определяет, где откроется раздел Sessions при следующем запуске. Если она выключена, приложение возвращается к основному шлюзу. Имена подключений нужно делать понятными, чтобы случайно не отправить рабочую задачу на тестовый сервер.

Слайд 57. Ключи внешних инструментов

Раздел «Инструменты и ключи» хранит параметры интеграций, которыми пользуются отдельные инструменты. В списке видны настройки для браузерного движка агента, Brave Search, Browser Use, Browserbase, Camofox, Connector Gateway и ElevenLabs.

Часть полей содержит секретный ключ, часть — URL или идентификатор проекта. Необязательное поле можно оставить пустым, если инструмент не используется. Наличие ключа само по себе не включает соответствующий навык или группу инструментов: доступ должен быть разрешён и на уровне возможностей агента.

Я добавляю ключ только перед использованием конкретной интеграции и проверяю её минимальными правами. Если сервис поддерживает отдельные проекты или лимиты, для Hermes лучше создать самостоятельную учётную запись. Это упрощает отзыв доступа и контроль расходов.

Слайд 58. Параметры коннекторов и каналов

Вкладка «Настройки» содержит переменные для коннекторов и каналов связи. Среди них видны разрешения A2A, домашний канал A2A, доступ всех пользователей BlueBubbles и Buzz, домашние каналы DingTalk и Discord, а также имена этих каналов.

Параметры вида Allow All Users определяют, разрешены ли сообщения от любого пользователя. В рабочей среде безопаснее оставить общий доступ выключенным и настроить явный список разрешённых отправителей. Home Channel задаёт канал, который интеграция использует по умолчанию для входящих сообщений или публикации результата.

Эти значения дополняют настройки конкретного мессенджера. После изменения нужно проверить канал тестовым сообщением и убедиться, что ответ получает только ожидаемая аудитория. На этом завершается обзор: Hermes объединяет модель, инструменты, память, внешние каналы и шлюз, а надёжность всей системы зависит от точной настройки каждого слоя.
